

学校代码：10285
学 号：20195227076



硕士学位论文

(专业学位)



纠删码存储系统中的数据修复技术研究

Research on Data Repair Techniques in
Erasure-Coded Storage Systems

研究生姓名 叶冬冬
指导教师姓名 郑朝晖
专业名称 计算机技术
研究方向 分布式存储
所在院部 计算机科学与技术
论文提交日期 2022 年 6 月

苏州大学学位论文独创性声明

本人郑重声明：所提交的学位论文是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含其他个人或集体已经发表或撰写过的研究成果，也不含为获得苏州大学或其它教育机构的学位证书而使用过的材料。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人承担本声明的法律责任。

论文作者签名: 张序 日期: 2021.6.8

苏州大学学位论文使用授权声明

本人完全了解苏州大学关于收集、保存和使用学位论文的规定，即：学位论文著作权归属苏州大学。本学位论文电子文档的内容和纸质论文的内容相一致。苏州大学有权向国家图书馆、中国社科院文献信息情报中心、中国科学技术信息研究所（含万方数据电子出版社）、中国学术期刊（光盘版）电子杂志社送交本学位论文的复印件和电子文档，允许论文被查阅和借阅，可以采用影印、缩印或其他复制手段保存和汇编学位论文，可以将学位论文的全部或部分内容编入有关数据库进行检索。

涉密论文

本学位论文属 在____年____月解密后适用本规定。

非涉密论文

论文作者签名: 张宇 日 期: 2021.6.8

导师签名: 李正华 日 期: 2021.6.8

纠删码存储系统中的数据修复技术研究

摘要

句法分析任务是句子理解的重要中间过程之一。其中，概率估计一直是句法分析领域的一个核心问题。然而，无论是神经网络方法还是深度学习时代以前的方法，采用基于全局概率模型的句法分析工作都非常少，主要的原因在于树形条件随机场(TreeCRF)推断的高复杂度。在本文中，我们提出将TreeCRF应用到依存句法和成分句法这两个主要的句法分析任务。为了解决TreeCRF的低效问题，关键的想法是批次化树结构的推断算法，并且用基于自动求导的反向传播代替Outside算法。目前句法模型被不断简化，采用局部损失目标是当前句法分析方法的一个趋势，我们则进一步在一阶TreeCRF的基础上采用了高阶拓展。高阶TreeCRF进一步增加了算法复杂度，为此，我们还提出利用基于平均场变分推断的近似推断算法代替精确推断的TreeCRF方法，从而增加了解析效率。

关键词：句法分析，依存句法分析，成分句法分析，树形条件随机场，变分推断

作者：叶冬冬

指导老师：郑朝晖

Research on Data Repair Techniques in Erasure-Coded Storage Systems

Abstract

Syntactic parsing is one of the most important intermediate processes in sentence comprehension, and probability estimation has always been a core problem in the parsing field. However, in either deep learning (DL) era or pre-DL era, there exist very few works based on global probabilistic modeling, mainly due to the high complexity of tree-structure CRF (TreeCRF) inference. This thesis proposes to apply TreeCRF to both dependency parsing and constituency parsing. The key idea to solve the inefficiency issue is to batchify the inference algorithm for tree structures, and meanwhile avoid the complex Outside algorithm via back-propagation. Currently, parsing models are greatly simplified, and it's a trend to adopt local loss for syntactic parsing. In contrast, we propose a high-order extension to first-order models. While high-order modeling further increases the algorithm complexity, we also try to apply mean field variational inference (MFVI) as an alternative to exact inference of TreeCRF method, which greatly improves the parsing efficiency.

Key words: Syntactic Parsing, Dependency Parsing, Constituency Parsing, TreeCRF, Variational Inference

Written by Dongdong Ye

Supervised by Zhaohui Zheng

目 录

第一章 绪论	1
1.1 分布式存储系统概述	1
1.2 数据容错技术概述	2
1.2.1 结构容错机制	3
1.2.2 数据容错机制	3
1.3 纠删码概述	5
1.3.1 Reed-Solomon 码	6
1.3.2 基于阵列结构的纠删码	8
1.3.3 基于网络编码的纠删码	10
1.3.4 基于分组结构的纠删码	11
1.4 基于纠删码的数据修复技术	12
1.4.1 基于星型拓扑的数据修复	13
1.4.2 基于树型拓扑的数据修复	14
1.4.3 基于 XOR 的纠删码数据修复	15
1.5 纠删码及修复技术的问题和挑战	16
1.6 论文主要研究内容	16
1.7 论文组织结构	16
第二章 相关研究	17
2.1 基于感知修复的研究现状	20
2.2 基于改进纠删码结构存储数据研究现状	20
2.3 基于调度优化的数据修复研究现状	20
第三章 面向纠删码构建的存储系统中预测修复技术研究	21
3.1 预测修复算法	21
3.2 修复调度算法	21
3.3 实验结果分析	21
第四章 面向纠删码构建的存储系统中修复调度研究	22
第五章 基于预测修复的纠删码存储系统原型设计与实现	23
第六章 总结与展望	24
参考文献	25

攻读学位期间的成果	31
攻读学位期间的主要科研工作	32
致谢	33

第一章 绪论

1.1 分布式存储系统概述

信息技术以及数据存储技术的发展引起了重大且深刻的社会变革，以相当程度地促进了科技的进步与发展，并且随着信息技术与数据存储技术在社会生活中的不断渗入，电子数据的产生数量与速度都呈现着爆炸式的增长。根据 IDC (International Data Corporation, 国际数据公司) 预测，全球数据量将从 2020 年的 44ZB 增长到 2025 年的 175ZB^[1]。在此如此急剧增长的数据体量面前，传统的数据存储方式已然无法满足时代对于数据存储的需求，所以如何保证数据的安全存储以及便捷读取成为当前时代的一个非常重要的课题。

伴随着用户电子数据的不断增长和存储需求的不断增加，分布式存储系统凭借便捷性、统一性、安全性、可靠性得到了广泛的应用，并且逐渐成为了当今信息社会的网络基础设施。分布式存储系统结合了负载均衡技术、集群技术、虚拟化技术、分布式技术、CDN 加速技术，为用户提供了数据存取的方便以及快捷且低成本的文件存储服务。

但是，目前流行的云存储系统普遍依赖中心服务器来提供云存储和数据处理服务^[2]。存储节点本身硬件故障或者技术原因导致的风险、设备陈旧需要替换或软件升级等原因使这些存储服务器十分容易出现短时或永久性的失效，从而导致存储的数据永久性的丢失。例如：2018 年腾讯云因磁盘故障导致文件元数据的丢失，大量的个人用户资料数据丢失；Sathiamoorthy 等^[3] 曾指出 “Facebook 数据中心的一个大集群在一个月内的节点故障数目超过 20 个而一天内失效节点的数量峰值可高达 100 个”。因此如何提高分布式存储系统的数据可靠性亦即数据修复技术是业界和学术界广泛关注的问题。对于可靠性低且经常发生故障的海量存储节点，如何采用性能优越的技术和措施才能保证数据的可靠性和故障发生时如何以相对低廉的成本快速修复故障节点的数据，已然成为了大规模分布式存储系统的重要目标和方向。

目前，分布式存储系统通常采取存储超过原本数据 1.x 倍的冗余数据来保证数据可靠性以对抗节点故障而导致的数据丢失，进而通过冗余数据进行相关的计算还原出丢失的数据。分布式存储系统中冗余数据的产生方法大致可以分为两类：

- (1) 多副本方式，即将数据对象复制多份（通常为三份），如 r 份，然后将这些

副本均匀地分散到 r 个不同的存储节点上，当某个节点故障时，只需要从剩下任意节点中下载原文件 $r - 1$ 次，并将其重新存放到其他正常节点即可。但是在数据存储急剧增长的情况下，备份冗余会引发大量存储开销，早期的分布式集群一般采用这种方式。其中典型的代表有 Google File System^[4]，Hadoop Distributed File System^[5] 等。

(2) 纠删码方式，即使用纠删码（erasure codes）技术生产冗余数据块。纠删码是通过编解码矩阵的计算创建了远小于多备份技术的冗余数据，同时提供同级别的容错性^[6]。如今的大规模存储群越来越多地采用纠删码 (Ford 等^[7], Huang 等^[8], Muralidhar 等^[9], Ovsianikov 等^[10])，进而取得存储空间和可靠性二者之间的均衡。具体的编码方式则是将原始文件计算分割成若干个数据块，再进行编码生成多个冗余的编码块，并将这些编码块存储到不同的节点上。与多副本方式相比，在存储同样体量的原始文件与同等的数据可靠性的条件下，纠删码的优点在于能够极大地节省了存储空间，进而减少了存储空间上的开销。目前学术界有大量的纠删码的编码方式，如 Reed-Solomon 码（简称 RS 码）^[11]，Regenerating Code（简称 RGC 码）^[12]，Local Regeneration Code（简称 LRC 码）^[13] 等。

无论是多副本技术还是纠删码方式都会产生冗余数据，并且都有其固有的缺陷。多副本技术有着极大的存储空间开销，为了能够容忍 $(m - 1)$ 个副本失效，而不得不额外消耗 $(m - 1)$ 倍于原始数据大小的存储空间，例如三副本机制在大数据时代，当数据规模达到 PB、EB 甚至 ZB 级别时，多副本技术极高的存储空间成本以及维护开销将使得数据中心无法承担。除此之外，纠删码自身也存在着相应地无法忽视的缺陷，例如修复成本过高、消耗大量的 CPU 资源进行编解码操作、实现过程复杂等，从而使得将该技术应用到分布式存储系统中时面临着诸多挑战。

1.2 数据容错技术概述

为了保证分布式存储系统中的数据可靠性和可用性，系统本身必须采取一定的数据容错技术。数据容错技术是指通过某种方式对数据对象进行处理后产生的一定的冗余，并将处理后的数据发送到不同的节点上，使得如果由于某些节点故障导致的数据失效时，能够使用剩下节点中的数据还原出丢失的数据。

为了保证系统中数据的实时可访问性，在部分数据因节点故障而丢失时必须利用健康节点上的剩余数据快速地将数据重新恢复出来，此过程被称为“**数据修复 (Data Repair)**”^[14]。维持数据原有的冗余度是数据修复技术想要达到的目的，同时也要确

保数据的可靠性。因为对于数据容错技术而言，能够容忍的数据丢失是极其有限的，一旦丢失的数据超过了容错技术的容忍度，原本的数据对象将无法恢复，从而导致数据的永久性丢失。一般的数据修复过程主要遵循以下过程：当系统检测到节点故障事件产生时，根据系统设定的容错方案开始进行启用对应的修复方案，利用剩余的健康数据节点对丢失的数据进行恢复，再将其重新根据放置算法将数据分散存储到存活节点中去。修复时提供数据的节点称为提供节点，修复出的数据存在的节点称为新生节点。分布式存储系统冗余机制可以分为结构容错机制和数据容错机制。

1.2.1 结构容错机制

结构容错机制实现系统容错的方式是通过提供冗余的物理设备的方法来实现的。具体的分类方式是根据冗余物理设备的不同可以分为以下两种：基于节点冗余的冗余机制和基于链路冗余的容错机制。

基于节点冗余的容错机制实现文件冗余的方式是使用增加冗余节点的方式实现的。当系统中的某个数据节点失效以后，系统将使用冗余节点替代失效节点^[4,15,16]。

基于链路冗余的容错机制则是通过增加冗余的网络链路的方式来实现文件冗余。主要通过两种方式进行实现，其中之一为通过在树结构的上层链路加入冗余链路来提高系统容错性^[17,18]，或者通过在服务节点上添加网卡的方式实现多链路冗余^[19,20]。

1.2.2 数据容错机制

在传统的分布式存储系统中，用户节点通过将文件切块后再将数据块分发到存储节点中。通过创建冗余的数据编码块来对分布式存储系统的容错能力进行提高的方式被称为数据容错机制。根据冗余数据编码块创建方式的不同，数据容错机制可以分为基于复制的容错机制和基于编码的容错机制。

基于复制的容错机制原理如图 1-1 所示，将原始数据复制多份，创建多个数据副本并分发到不同的存储节点上从而实现数据冗余^[4,21,22]。当一个或者多个存储着原始文件副本数据的存储节点故障时，系统通过访问其他存活节点的原始文件的副本数据，进行数据的恢复，进而提高系统的可靠性。基于复制的冗余机制原理较为简单，易于部署和实现，并且在确保数据可靠性的基础上还能提高数据的并发访问能力。然而，缺点显而易见，在文件储存过程中，需要分发多个多个数据副本，因此提高了数据的存储开销和通信数据的开销，存储效率较低。对于 n 副本的复制容错机制，系统

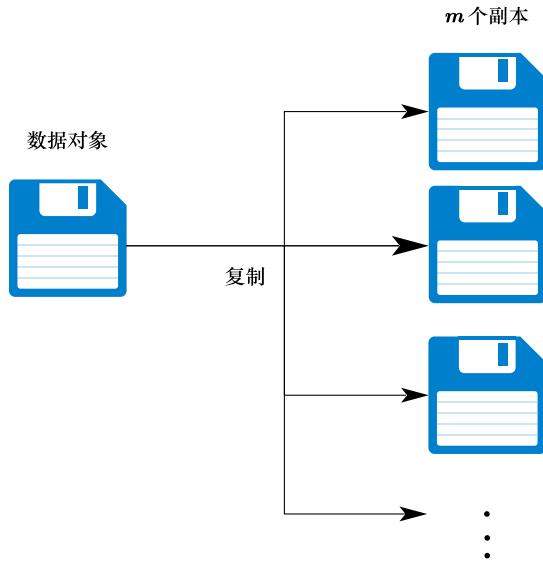


图 1-1 基于复制的容错机制原理

存储空间的总体利用率只有 $\frac{1}{n}$ 。在此基础之上，为了提高存储效率，降低存储空间的开销，可以采用动态复制机制，依据系统的网络状况、用户需求等因素进行综合考量并进行动态创建与删除副本^[23–25]。但是，动态复制技术也存在其固有的缺陷，因为在动态创建与删除副本的过程中，需要 CPU 执行大量的计算，并且需要进行频繁的数据分发，从而增加了系统的计算开销和通信开销。

相对应的，基于编码的容错机制首先对原始数据文件进行切块，再对切成的块文件进行编码，生成体积较小的编码块从而提高数据可用性。基于编码的容错机制生成的编码块体积小、数量少，因此，相对于基于复制的容错机制，具有较小的存储开销。基于编码的容错机制可以分为两种：RAID 技术、纠删码容错。

RAID 技术^[26,27]是一种传统的基于编码的容错技术，RAID 技术实现容错的方式是通过将数据进行条带化，然后将数据条带分发到不同的存储节点上，并生成一个编码块进而实现数据的容错与冗余。RAID 技术一般只能容忍一到两个数据块的失效，因此对于大规模的分布式存储系统而言，RAID 技术无法满足其数据可靠性的要求。

更加主流的基于编码的容错方式便是纠删码技术，其本身是一种编码容错技术，最早被应用到通信领域，解决数据在传输中的纠错问题。传统的纠删码技术实现容错机制的步骤一般如下，首先将原始数据文件分割成 k 个数据块，然后将这些数据块通过相应的矩阵计算进行编码生成 $n - k$ 个编码块，最后将生成的 k 个数据块和 $n - k$ 个编码块分发到不同的存储节点中。当用户访问存储系统下载数据时，只需要从 n 个数据块中任意下载 k 个可用的块即可恢复出完整的原始数据文件。

相较于基于复制的容错技术即多副本技术，纠删码技术最大的优势是能够以极低的存储空间开销代价换取相同甚至更高级别的数据可靠性^[6,28]。例如，RS(12, 10)码可以凭借 0.2 倍的额外存储空间开销获取两个节点的容错能力，这比具有同等容错能力的三副本技术节省了约 60% 的存储空间。在同等的存储空间利用的情况下，以纠删码技术构建的分布式系统的数据可靠性比采用多副本技术构建的分布式存储系统中的数据可靠性要大几个数量级^[6,28]。尽管有很多代表性的工作 (Reed 等^[11], Huang 等^[29], Xu 等^[30], Roth 等^[31]) 对于纠删码的计算性能进行了优化，但是纠删码方案由于其固有的缺陷如大量的矩阵计算编解码操作，依然会产生巨大的通信开销。因此如何提高纠删码容错的效率是一个亟需解决的重要问题。

1.3 纠删码概述

近年来，越来越多的大规模存储系统采用了具有较强容错能力和空间利用率较高的纠删码实现系统冗余 (Xia 等^[32], Kubiatowicz 等^[33])。随着时代发展，数据规模越来越大，如何提升纠删码的容错能力用以满足系统的存储和访问需求已然成为学界与业界广泛关注的问题。

纠删码的主要思想是把一个数据对象 D 分为 k 个相同大小的数据块，通过一定的矩阵计算和编码算法生成 n 个块 ($n > k$)，使得通过其中任意 k' 个块即可重新还原出原始数据，具体过程如图 1-2 所示。

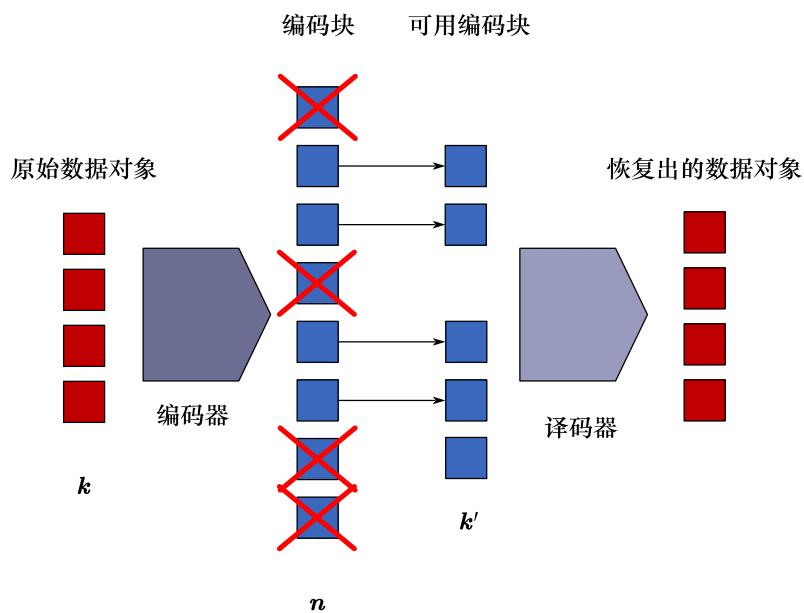


图 1-2 纠删码编码和解码示意图

一般来说，纠删码可以用三元组 (n, k, k') 表示。其中 k 是数据切分成的数据块个数， k' 是一个不小于 k 的数， n 是编码后的块数。首先，将数据对象 D 分割成 k 个大小相等的数据块 D_1, D_2, \dots, D_k ，然后通过编码算法和矩阵运算将这 k 个数据块进行编码，生成 n 个同等大小的编码块 $I_1, I_2, \dots, I_n, n > k$ ，使得通过其中任意 k' 个块都能还原出原始的数据对象 D 的对应的 k 个数据块 D_1, D_2, \dots, D_k ，从而组合出原始的数据。纠删码可以容忍的最多失效块的个数称为容错度，当 $k = k'$ 时，纠删码达到理论上的最高容错力，称之为最大距离可分码（Maximum Distance Separable，简称 MDS 码）^[34]。这样的纠删码可用二元组 (n, k) 表示，如果纠删码生成的 n 个块集合中包含全部的 k 个原数据块，这样的纠删码便是系统码（System Code）^[35]。对于系统码而言，编码后生成的额外 $n - k$ 个块称为编码块，并且记为 P_1, P_2, \dots, P_m ，其中 $m = n - k$ 。如果数据块没有丢失，应用系统码的存储系统在相应数据访问操作时无需进行解码操作，性能大大提升，这也是现有的纠删码大多是系统码的原因。

在存储系统实际的运行过程中，先将文件分割成固定大小的数据块，再将这些数据块每 k 个作为一组，每组独立进行编码操作生成 n 个块，其中 n 个块的集合称为一个条带（Stripe）^[36]， k 称为条带长度（Stripe Length）。当数据对象的块数不是 k 的整数倍或者最后一个数据块不足一个整块时，以 0 填充，被 0 填充的部分不需要存储在真正的磁盘上，在数据修复时也不需要读取。根据计算方式和几何构造的不同，纠删码可分为 Reed-Solomon 码、阵列结构型纠删码、网络编码型纠删码和分组结构型纠删码。

1.3.1 Reed-Solomon 码

Reed-Solomon 码^[11]是最为经典的 MDS 码，是唯一可以用任意的数据磁盘数目和任意冗余磁盘数目的 MDS 码。RS 码的编码原理是通过矩阵的运算来完成的，如果分布式存储集群采用的是结构为 $(k + r, r)$ 的 RS 编码，则整个分布式存储集群应具有 k 个数据块和 r 个编码块。在基于 RS 编码的分布式存储集群中，如图 1-3 所示，编码块是通过将 k 个数据块与 $k \times (k + r)$ 个生成矩阵相乘来构造的，该生成矩阵主要包含了两个变量，一个 $k \times k$ 校验矩阵和一个 $k \times r$ 冗余矩阵^[37]。一个由 $(k + r, r)$ 组成的 RS 编码存储集群，含有 $k + r$ 个存储节点的阵列，其中 k 个数据块和 r 个编码块分别存储在存储集群中的 k 数据节点服务器和 r 个奇偶校验节点服务器上。

RS 码实际上是利用生成矩阵和数据列向量进行矩阵乘法得到编码列向量。RS 码

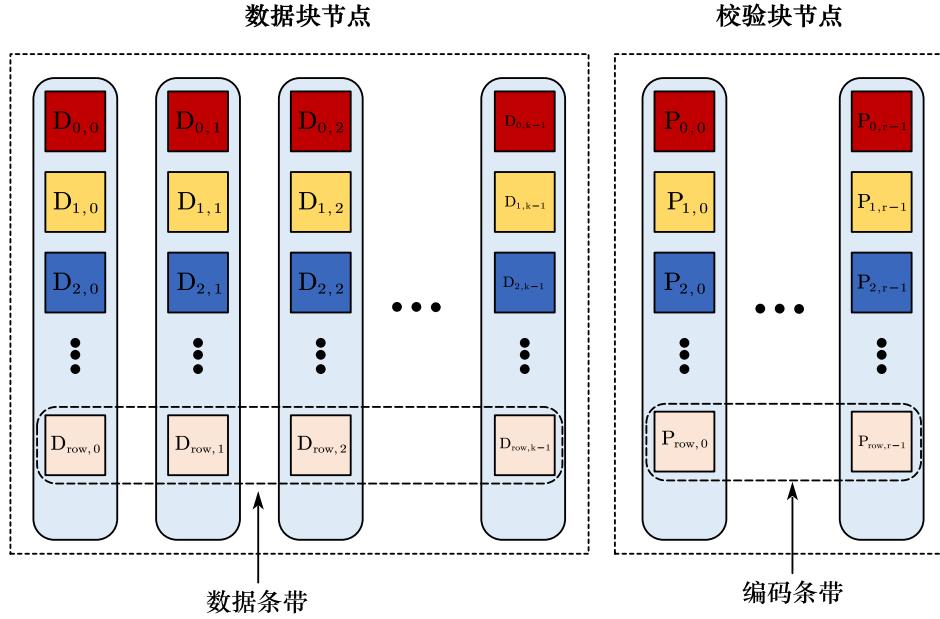


图 1-3 传统基于 RS 码结构的存储集群布局

使用的生成矩阵 G 中的任意 k 行组成的矩阵需要在 Galois 域上可逆，故获得生成矩阵的计算量并不低，且可由范德蒙德（Vandermonde）矩阵或柯西（Cauchy）矩阵^[31]通过变换得到。采用前者计算方法的 RS 码称为范德蒙德 RS 码，采用后者计算方法的 RS 码称为柯西 RS 码。在 Galois 域上，加法的定义是异或运算，乘法则需要使用离散对数运算和查表，因此计算开销很大，而应用柯西矩阵可将乘法运算转化为二进制的乘法运算，从而减轻运算量。

RS 码拥有比传统多副本容错更高的容错能力和更高的灵活性。RS 码不仅达到了理论上的最高容错能力，而且其条带长度 k 可以取任何大于 0 的整数，编码后产生块数 n 可以取任何大于 k 的整数。 n 相对于 k 越大，RS 码的容错能力越高，但存储空间消耗也越多。因此，RS 码在可靠性和存储空间开销方面给予了系统很大的选择空间。

然而，纠删码的其中一个弊端在于会引起大量的带宽以及计算资源的消耗，进而导致存储效率的降低。由于计算能力的限制，RS 码从诞生起其编解码算法就已被广泛研究和优化，计算复杂度高的问题已被较好地解决。近年来各种硬件的计算能力的显著提升，在分布式存储系统中进行编解码运算并不会占用过多的计算资源。与 RS 码在信道中纠错时不同，当 RS 码作为分布式存储系统的数据容错技术时，由于其产生的 n 个编码块必须分别放在 n 个不同的节点上，若只有一个丢失，在进行数据修复时也需要从不同节点下载 k 个编码块。这是多副本技术中修复一个块需要数据量的 k

倍，会占用大量的网络资源，并极大地降低了修复速度。

RS 码高昂的修复成本使其在分布式存储系统中的应用有很多亟待解决的问题。然而，RS 码高容错和低空间消耗的优点对提高分布式存储系统的数据可靠性和降低其经济成本具有重大意义。为了解决这一问题，涌现出了众多修复成本较低的纠删码。这些低修复成本的纠删码根据其采用的基本技术可以分为三类：基于阵列结构的纠删码、基于网络编码的纠删码和基于分组结构的纠删码。

1.3.2 基于阵列结构的纠删码

阵列码是一种采用阵列结构编码且完全基于异或运算的纠删码，从冗余磁盘阵列 (RAID)^[26] 技术中不断发展出来。阵列码的含义就是将原始的数据和冗余的数据一起存储在一个二维的阵列中。根据数据块和编码块放置方式的不同，阵列码可以分为横向阵列码和纵向阵列码。

横向阵列码 (horizontal parity array codes) 的特点是将数据块和相应的编码块分发到不同的数据节点上。它的结构特点是将冗余的数据单独放到独立的磁盘中，这些磁盘也被称为冗余磁盘，而让别的磁盘专门用于存储数据，这样做好处是可扩展性很强。

EVENODD 编码^[38] 是最早被发表的阵列码，EVENODD 码的编码块和数据块之间的计算关系如图 1-4 所示。其中第一列上的编码块分别由各自同一行上的其他数据块进行异或得到，第二列上的编码块由与其直线相连的对角线上的数据块进行异或运算得到。此外，RDP^[39] 编码也是一种应用较为广泛的横向阵列码，这些编码体系均对磁盘数目提出了严格的要求（要求磁盘数目必须是素数或者素数减 1），同时还要求在单个条带中的数据元素的个数必须与磁盘的数目相匹配。

除了 EVENODD 和 RDP，其他的横向阵列码有 EEO^[40]，STAR^[41]，RAID-6 Liberation^[35] 和 Feng's Code^[42] 等，它们具有性能比较优秀的编码效率和极高的存储空间利用率。由于横向阵列码本身固有的缺陷，如写入数据总会用到冗余磁盘，故其中的 I/O 流量成为了横向阵列码的性能瓶颈。

纵向阵列码 (vertical parity array codes) 是指冗余存储在数据条带中的阵列编码方式，即冗余数据和原始数据混合放在磁盘中的纠删码。由此可以看出纵向阵列码将计算工作和写入操作均匀地分摊到各块磁盘上，从而实现了负载均衡。X-code^[30] 是具有 MDS 性质的纵向纠删码，其在编码操作，数据更新以及数据重构等步骤上具有

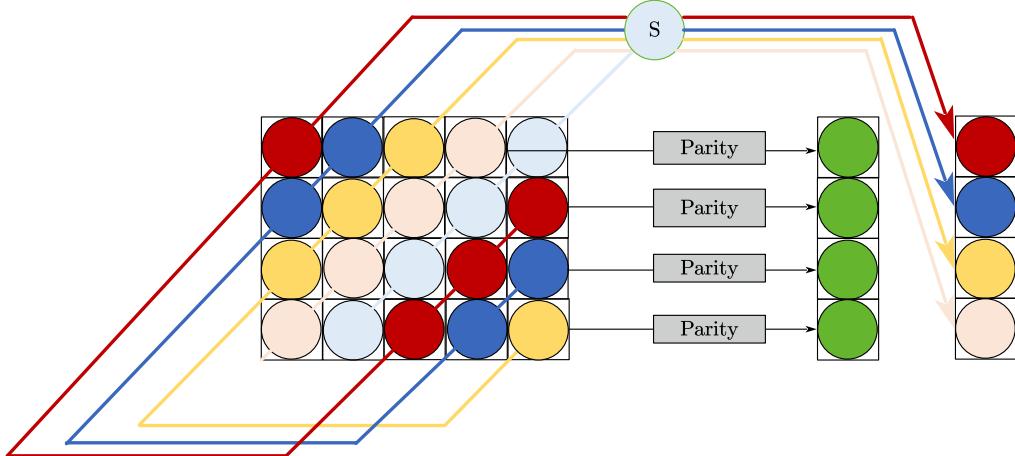


图 1-4 EVENODD 码的编码结构示意图

理论上的最优效率，缺点就是可扩展性比较差。

X-code 的编码方法如图 1-5 所示，同一列上的数据块与编码块表示存储在同一个存储节点中，存储节点上包含 k 个编码块。其中红色块代表数据块，蓝色块代表编码块， n 需要是一个大于 2 的素数，数据个数必须为 $n - 2$ 个，编码块的个数也必须是 2 个。此外，第一个编码块由主对角线上的数据块进行计算得到，另外一个编码块由副对角线的数据块计算得到，这些计算需要用到 k 个磁盘上的数据块，计算成本较高，且修复时需要按照一定的顺序进行计算，失去了并行修复的可能，这些均是 X-code 的不足之处。

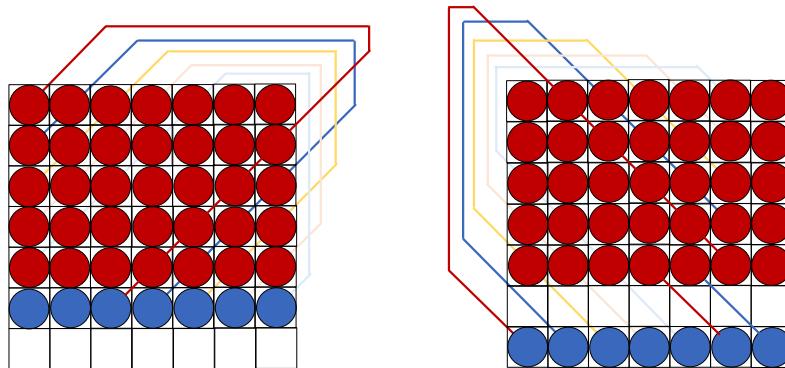


图 1-5 X-code 的编码结构示意图

阵列码在计算上的主要特点就是所有的运算都是异或运算，相较于传统的 RS 编码在计算性能上有优化，但需要的数据量却并没有丝毫减少，传输的数据量较大。

1.3.3 基于网络编码的纠删码

网络编码最初由 Ahlswede 等^[43]于 2000 年首次提出。在传统的网络路由中，中间节点只具备存储和转发的功能。而网络编码则增强了中间节点的功能，使得其不仅可以存储转发数据，并且还可以在转发数据之前对数据进行编码和组合计算，从而减少了网络中的数据传输量并提高了网络吞吐率。

Dimakis 等^[44]将网络编码的思想应用到纠删码上并称之为再生码 (Regenerating Codes)。再生码允许新生节点访问多于 k 个节点，从而显著降低修复过程需要传输的总数据量。




图 1-6 再生码修复失效数据节点示意图

图 1-6 显示了再生码修复失效数据节点过程，总共有四个用来存储数据的节点，并且每个存储节点上存放着两个数据块，并且是通过相关的矩阵运算生成的。若第一个存储节点发生故障时，则相应的存储的数据块会丢失。针对此种情况，传统纠删码的修复方法是在剩下的三个存储节点中任选两个，将这两个节点的所有数据块发送给新生节点 (newcomer)，传输数据块的总数目为 4。而再生码的思想是首先在存储节点中进行相应的计算后再进行数据分发，传输数据块的总数目为 3，相较于传统的修复方法，再生码修复数据传输量降低了 25%。

Dimakis 等^[44]提出的再生码可以对丢失的数据进行精确修复，但对编码块只能进行功能性修复。所谓功能性修复，亦即修复出的数据与原来的冗余数据并不是一模

一样的，但却可以维持数据的容错度不变。针对此问题，Wu 等^[45]提出了确定性再生码 (Deterministic Regenerating Codes)，并从概率学角度证明了其存在性。

根据存储效率的不同，再生码可以分为 $\frac{k}{n} \leq \frac{1}{2}$ 的低比特率码和 $\frac{k}{n} > \frac{1}{2}$ 的高比特率码。它们可以在一定程度上从源头减少修复过程中传输的数据量，但是由于编码系数所在域的要求限制和选择方法的不规则，难以实现等原因，目前应用并不广泛。

1.3.4 基于分组结构的纠删码

基于分组结构的纠删码可以减少数据修复时需要下载的数据量，因传统的 RS 码在修复一个丢失的块时需要下载的数据条带长度为 k ，而分组结构的纠删码的方法则是将 k 减小从而达到降低数据量的目标。分组编码的纠删码首先将数据条带分成若干组，各个组各自计算相应的编码块，实现组内修复丢失块，需要的块数则取决于每个组内的数据块数。而相应的，RS 码作为一种特殊的分组编码，将整个数据条带作为一组，此外根据分组方法的不同，此类纠删码可以分为两类：水平分组结构的纠删码和交叉分组结构的纠删码。

比较经典的水平分组纠删码一般是将数据条带分为两组。每个小组生成一个局部的冗余块，然后整个条带再生产一个全局的冗余块。这样数据修复就可以依靠小组内的编码块完成，降低了修复成本。图 1-7 显示的是微软的 Azure 系统^[46]采用 LRC (Local Reconstruction Codes)^[8]的一个实际的例子 LRC(8,2,2)。可以看出，它将数据块平均分为了两组，每组各自内部计算出一块局部冗余编码块，相当于一个 RS(5,4) 码。对于两个条带再生成 2 个全局的校验块，则相当于一个 RS(10,8) 码。当丢失块数不多时，如 1 个则只需要 4 个块即可进行数据修复，这样就有效降低了修复成本。

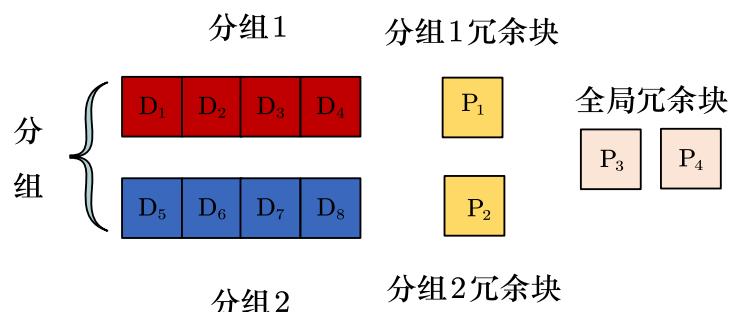


图 1-7 LRC(8, 2, 2) 的编码示意图

由此可以发现，组数越多，那么可以容忍的失效的块数也就越多，故 Pyramid

码^[47]便诞生了，它的特点就是可以对条带内的数据块进行任意层次的分组，层次越多平均的修复成本也就越低，但是相对的存储空间消耗也就越大，因为产生了更多的全局校验块，对于 Pyramid 码需要根据实际的存储系统环境选择更加适中的方案。除此以外水平结构的编码还有运行在 Facebook 旗下的分布式存储系统中的 XORing Elephants^[3]、EXPyramid^[48]、LRCs^[3]等。EXPyramid 码是对两层 Pyramid 码的一种改进，其分为了三组。

交叉分组结构的纠删码与水平分组不同之处大致有两点。第一，交叉分组纠删码的分组方式不同，交叉分组的各组之间相互重叠但却互不包含，相比之下水平分组各组之间一般不重叠且会有一个全局的校验块包含着各个分组的校验块。第二，交叉分组纠删码编码计算较为简单，基于异或计算。不难看出，交叉分组有着相对来说较低的计算性能消耗的优点。常见的交叉结构的纠删码有 Woitaszek 等^[49]提出的 Tornado 码，如图 1-8 所示，其任何组别的冗余块均为组内的数据块的校验块，并且修复任何一个数据块或者冗余块只需 4 个或 3 个块，避免了大量下载编码块的特殊情况。此外还有 LDPC^[50]、WEAVER 码^[51]和 Tanner 码、Hover 码^[52]等。




图 1-8 Tornado 码的构造示意图

1.4 基于纠删码的数据修复技术

在基于纠删码的分布式存储系统中，数据传输并不是简单的线性路线，修复一个丢失的数据块时，提供者节点要向新生节点传输多个数据块用以完整地修复数据，数

据的传输路径往往比较多样化，根据传输路径的不同一般可分为三种修复技术：基于星型拓扑的数据修复、基于树型拓扑的数据修复和基于 XOR 的纠删码数据修复。

1.4.1 基于星型拓扑的数据修复

基于星型拓扑的串行修复技术（Star Structure Based, SSR）是指依序逐个修复故障的节点数据，每个故障节点的修复过程都是按照星型拓扑来进行的。具体来说，以新生节点为中心，各个存活节点之间并不相互传输数据，存活节点直接向新生节点传输数据，从而形成了一个以新生节点为中心、存活节点为边界的星型拓扑结构。可以看出，修复的时间取决于新生节点与存活节点之间最慢的一条带宽链路。

Dimakis 等^[44], Wu 等^[45]提出的再生码数据修复过程要求每个存活节点向新生节点传输均等的数据量进行修复，数据收集节点（DC 节点）仅连接 k 个节点，通常是 $k - 1$ 个数据节点和第一个校验数据节点，并从每个节点下载 $\frac{M}{k}$ 的数据量（ M 为原文件大小）。这里存在一个非常明显的缺陷，节点可以选择的链路比较单一，带宽较高的链路很有可能会被忽视，导致修复效率降低。Shah 等^[53]提出了弹性修复的方法，即允许存活节点和 DC 节点充分利用所有可用的链路，从中选择带宽较大的链路进行数据传输，传输的数据不均等。DC 节点从节点 $i(1 \leq i \leq n)$ 下载 $\mu_i(0 \leq \mu_i \leq \alpha)$ ，满足总下载量不小于 M 即可。同理，新生节点从存活节点 $i(1 \leq i \leq n)$ 接收 $\beta_i(0 \leq \beta_i \leq \beta_{max})$ 数据量，满足总接收量大于或等于一个设定参数 γ 即可，用不等式表示则如 1.1 和 1.2：

$$\sum_{i=1}^n \mu_i \geq M, 0 \leq \mu_i \leq \alpha \quad (1.1)$$

$$\sum_{i=1}^n \beta_i \geq \gamma, 0 \leq \beta_i \leq \alpha \quad (1.2)$$

当一个节点故障时，新生节点可以选择任意 k 个节点下载 $\frac{M}{k}$ 的数据量，修复带宽相等于原文件大小。对于弹性修复方法而言，新生节点，可以根据可用带宽的大小从不同节点上下载不均等的数据来降低修复时间。当然星型拓扑的缺点也很明显，DC 节点需要收集多个节点的数据，修复速度会受到磁盘和网络 I/O 的限制，编解码的计算消耗也很大。

1.4.2 基于树型拓扑的数据修复

上节所描述的星型拓扑的技术其实是树型拓扑修复技术的特殊情况，然而修复速度受到了诸多的制约，为了提升修复的速度，树型拓扑修复方法因此被提出。

Li 等^[14,54]独辟蹊径地首次设计了一个新的基于网络带宽的树形修复方法（Tree-structured Data Regeneration），利用木桶原理并通过提高最低传输速度来加速数据的修复。这种修复方法中数据的传输路径称为修复树，修复树中所有节点都由提供者节点 (Providers) 和新生节点 (newcomer) 组成。提供者节点可接收别的提供者节点发来的数据并将其与本节点存储的数据进行计算，并将计算结果发给另一个提供者节点或新生节点。经证明，最大生成树是基于网络带宽的最优的修复树。

基于网络带宽的树形修复方法在一定程度上缓解了星型修复时新生节点由于同时接收大量数据造成网络拥堵。传统的星型修复中新生节点因为承担所有计算任务而导致负载重，而基于带宽的树形修复会将计算负载均衡到各节点，从而避免了此问题。最后，基于网络带宽的树形修复方法使得修复任务流水化，提高修复速度。但是基于带宽的树形修复的缺点也显而易见，由于带宽的实时动态变化速度很快，导致网络带宽不好测量或测量结果不准确，所以此方法在网络带宽不稳定的环境下有一定的局限性。

另一类树形结构的修复技术是基于网络拓扑的树形修复技术，最具代表性是 NTar^[55]。NTar 考虑了两种因素，包括网络上传输的数据量和数据传输过程中的网络距离。网络距离指的是两个节点之间的物理链路数目，单位为跳 (Hop)。这种技术将修复操作对系统资源的占用看做是修复过程传输的数据量和这些数据经过的交换设备数目的乘积。相较于传统的树形修复技术，单纯地用数据流量来衡量修复操作对系统资源的占用情况，基于网络拓扑的树形修复方法可以更精确地反映出数据传输对交换设备产生的影响。

在应对多节点失效时，现有的分布式存储系统采取的方法是顺序、独立地执行多个单节点修复过程。这样不仅造成多节点修复速度缓慢，而且还造成多节点修复时网络拥堵情况，严重影响了系统性能。为此，研究者们提出了基于树形结构的并行修复技术^[56]。基于树形结构的并行修复技术分为分离边策略和共享边策略。所谓分离边策略是指在同时构建修复树时，各个修复树的边不能在网络拓扑中重合。分离边策略的初衷是尽量让多个修复树使用不同的网络链路，从而充分利用网络资源，但此策略存在两个问题。第一个问题是让不同修复树中的边不重叠，在构建一个修复树之

后就将此树的所有边从网络拓扑图中删除，后续构建的修复树只能基于剩下的网络拓扑图。这样做的后果是网络拓扑图中边变得越来越少，如果同时需要构建的修复树数目足够多的话，将会出现无法继续构建有效修复树的情况。第二个问题是，即使拓扑结构中两个节点之间的网络带宽被前面的修复树占用了一部分，但剩余的空闲带宽仍可以很大。这时，如果将此条网络路径从网络拓扑中删除，将导致后续的修复树无法构建最优的修复树。为了解决上面两个问题，研究者们又提出了共享边的树形修复策略。顾名思义，共享边的数据修复策略在构建多个修复树时，不同修复树之间的边可以在网络拓扑中重合。此策略相比于分离边策略更加灵活，且实际效果更好。

1.4.3 基于 XOR 的纠删码数据修复

Xiang 等^[57]提出的基于异或运算 (XOR) 的纠删码低网络负载数据修复技术，专门用于优化 RDP 码^[39]修复失效数据所传输的数据量。Khan 等^[58]将其一般化，使其适用于任何基于异或运算的纠删码。基于异或运算的纠删码在编码之前，将每一个数据块分割成若干个大小相等的数据片 (segment)，按照某个具体的编码规则编码产生编码块，同样，每个编码块也是由若干个编码片组成，每个编码块中的各编码片经过几个数据片异或运算而产生。目前有三种比较主流的基于异或运算的纠删码数据修复方法，分别是提高降级读性能的 EG 算法修复方法、降低修复时间的 PHR 算法修复方法和降低修复成本的 CHR 算法修复方法。

提高降级读性能的 EG 算法修复方法针对的是降级读情况下的修复。节点失效的类型有两种，分别为永久失效和暂时失效，永久失效一般是指节点存储的数据丢失了，暂时失效是指节点存储的数据只是暂时不能读但依然还存储在系统中。对于前一种失效情况，系统进行失效修复 (failure recovery)，对于后一种，系统进行降级读 (degrade read)，降级读操作既要读可用数据，也要读不可用的数据，如果需要读不可用数据时，系统要进行相应数据的恢复操作。使用纠删码方式是通过矩阵计算的方式进行，当单个节点失效时，可用节点存储的编码块仍然可以用一个编码子矩阵表示，恢复数据的过程就是计算相应解码子矩阵的过程。针对节点带宽的异构性，Zhu 等^[59]提出了枚举贪心算法 (Enumerated Greedy Algorithm)，简称 EG 算法，EG 算法遍历所有 d 个可用节点可能的组合，在每一种组合下有 l 个 CDREs，计算每个 CDREs 的降级读时间，更新降级读时间，使每个块的降级读时间最小。

降低修复时间的 PHR 算法修复方法。Niu 等^[60]提出了针对 RAID-6 编码系统中

的多条带修复策略。这种策略将单个条带的修复过程分为了三个部分：读数据、编解码、写入数据。与此同时考虑了 I/O 并行性和节点的异构性，提出了并行异构恢复算法（parallel heterogeneous recovery），简称 PHR 算法，并且该算法能及时返回一个最优修复序列。应用 PHR 算法进行单条带数据修复时，三个阶段分别如下：1) 得到 PHR 算法输出的序列，从可用的磁盘上读取相应的数据和校验对象；2) 对读取到的对象进行解码得到丢失的对象；3) 将得到的对象写入其他健康磁盘上。虽然三个阶段是按顺序执行的，但是由于各条带的修复过程的相对独立性，可以通过多线程和流水线修复技术并行化修复过程，从而达到减少降级读的时间。

降低修复成本的 CHR 算法修复方法。对于一条链路上由于节点之间的带宽速度的不同而造成的传输一个元素的成本差异，Zhu 等^[61] 将传输成本和带宽资源联系起来，定义修复总成本为 $C = \sum_{i=0, i \neq k}^p w_i y_i$ ，其中假设节点 k 失效， w_i 表示从节点 i 读取一个对象的成本， y_i 表示从节点 i 读取的对象数目，进而他们提出了基于传输成本的异构恢复（cost-based heterogeneous recovery）算法，简称 CHR 算法。CHR 算法所有的最小读取量恢复序列进行枚举，并且计算这些序列的修复成本的总和，返回其中最小的总修复成本对应的修复序列。

1.5 纠删码及修复技术的问题和挑战

1.6 论文主要研究内容

1.7 论文组织结构

第二章 相关研究

目前实际的分布式存储系统经常独立地安排每个修复任务，鲜有考虑到任务彼此的影响。这些分布式的修复任务共享着底层基础设施的网络、计算和存储资源，这就造成了数据流之间的干扰，导致系统资源利用率低下。为了缓解这一问题，Popa 等^[62] 提出了 Elasticswitch，一种可以在各个服务器之间分配带宽的技术。通过这一技术，将服务器的总带宽资源进行整合，可以为每个修复任务分配必要的网络带宽。此外，系统中主要有三种任务需要优化执行，其中包括修复任务调度、调度数据的选择以及不同网段的后台修复任务的带宽分配。因此，Li 等^[63] 提出了 LSPT（Linear Programming for Selected Tasks）在满足数据放置、网络拓扑结构以及带宽限制的条件下，最大限度地增加满足时间限制的修复任务数。为了最佳地安排每个任务，LSPT 共同解决了 (1) 确定用于产生修复流量的纠删码块的选择问题，(2) 在修复任务之间分配 TOR 交换机和聚合交换机带宽的带宽分配问题，以及 (3) 根据最后修复时间限制安排任务的调度问题。假设一个数据存储中心的一个聚合交换机连接着 u 个机架交换器（Top-of-Rack）。 r 个存储节点 ($\mathcal{R} = \{1, 2, \dots, r\}$) 放置在 u 个机架内 ($\mathcal{U} = \{1, 2, \dots, u\}$) 并且每个 TOR 交换器。同一个机架内所有的节点的修复流量不需要经过聚合交换机，而不同机架上的存储节点之间的流量则不需要经过两个 TOR 交换机和聚合交换机。每份文件 i 用 (n_i, k_i) 纠删码进行存储，保证为 MDS（Maximum-Distance-Separable）码，确保 n_i 中的任意 k_i 块可以重建文件 i 。此问题可以描述为，令 $\mathcal{A} = \{A_1, A_2, \dots, A_m\}$ 表示为系统后台任务的集合，诸如备份，修复和数据再分配。对于每个任务 A_i ，相应地有关联参数包括数据块分发源 n_i （表示为 $o_{i,1} \in \mathcal{U}, o_{i,2} \in \mathcal{U}, \dots, o_{i,n_i} \in \mathcal{U}$ ），分发接收节点（表示为 $p_i \in \mathcal{U}$ ），需要获取的块个数 k_i ，每个块的大小 v_i ，任务开始时间 s_i ，以及任务的终止时间 d_i 。任务的开始时间和结束时间用秒作为单位，满足 $0 \leq s_i \leq d_i$ 。不失一般性，考虑带有时间段的系统，假设 $y_{i,j}$ 为编码块的选择变量，例如 $y_{i,j} = 1$ 表示块 j 被选择去执行任务 A_i ，而 $y_{i,j} = 0$ 则未被选中。既然块 k_i 必然被选择，则有

$$\sum_j y_{i,j} = k_i, \forall i \quad (2.1)$$

为了确定成功完成的任务数，使用二元变量 z_i 来进行表示，当 $z_i = 1$ 时任务 A_i 在时间限制内完成，否则未完成。设 $x_{t,i,j}$ 是在时间段 t 中分配给传输任务 A_i 的 j 块

的数据流量的带宽，如果任务在最后期限 d_i 之前完成，所有的 k 个块传输应该在 d_i 之间完成，即时间限制约束条件为：

$$\sum_{t=s_i}^{d_i} x_{t,i,j} y_{i,j} \geq v_i, \text{ if } z_i = 1, \forall i, \forall j \quad (2.2)$$

由于每个传输头尾对都有一个预先确定的路线，对于一个给定的任务集，用 RC_g 来表示跨越一个 TOR 或者聚合交换机 g 的任务或者块的集合，即 $(i, j) \in RC_g$ 如果任务 i 的块 j 的流量经过了交换机 g 。同样， SC_h 是经过节点 h 的任务或者块集合。每个 TOR 交换机有着容量的限制 CTA 且每个节点有着容量限制 CST ，因此有以下容量限制：

$$\sum_{(i,j) \in RC_g} x_{t,i,j} y_{i,j} \leq CTA, \forall g, t \quad (2.3)$$

$$\sum_{(i,j) \in SC_h} x_{t,i,j} y_{i,j} \leq CST, \forall h, t \quad (2.4)$$

任务的目标就是要在基于纠删码的存储系统中最大化在时间截止内成功完成的修复任务数。可以看做是一个联合调度和优化问题：

$$\begin{aligned} \max \quad & \sum_i z_i \\ \text{s.t.} \quad & \sum_j y_{i,j} = k_i, \forall i \\ & \sum_{t=s_i}^{d_i} x_{t,i,j} y_{i,j} \geq v_i z_i, \forall i \\ & \sum_{(i,j) \in RC_g} x_{t,i,j} y_{i,j} \leq CTA, \forall g, t \\ & \sum_{(i,j) \in SC_h} x_{t,i,j} y_{i,j} \leq CST, \forall h, t \\ \text{var.} \quad & x_{t,i,j} \geq 0, y_{i,j} \in \{0, 1\}, z_i \in \{0, 1\} \end{aligned} \quad (2.5)$$

其中式 2.5 的第三行正好对应式 2.2 任务成功时，即 $z_i = 1$ 。

MSR 改进。在多个同时发生的故障事件中，单个节点故障的恢复率可达到 98%^[64,65]。

因此，减少单一故障修复所产生的延迟对于提高系统性能是至关重要的。Dimakis 等^[44,66] 提出了再生码 RGC，它可以在存储开销和修复故障节点所需的数据量之间取得良好的均衡。另一方面，处于最小存储的再生码均衡点的 MSR (Minimum Storage Regenerating) 对于大部分纠删码来说是最优的替代选择，因为 MSR 可以在最小存储开销下实现最佳修复成本和最大距离可分 MDS 的特性。MDS 属性意味着只要故障块数小于或等于校验块数，那么数据就可以被恢复。然而，MSR 码有一些缺点。(1) 大多数现有的 MSR 码不是系统码，只在编码后存储奇偶校验块信息，因此造成了很高的计算开销；(2) 许多纠删码的存储开销超过系统存储量的 $2\times$ 倍，因此在实际存储系统中没有用处不大；(3) 存储开销低于系统存储量的 $2\times$ 倍的码不仅需要复杂且容易出错的代码策略，而且还需要很高资源的开销。对于这些问题，Butterfly^[67] 可以在低存储开销（低于 $2\times$ 倍）的情况下具有实际应用价值的 MSR 码，是一种系统化的码，读请求可以直接得到数据而不需要任何解码操作。然而，Butterfly 最多只能容忍两个块的故障，因此不能达到高可靠性的标准。此外，它还存在一个成簇的子包，它将块分成小的片段（最小的编码元素），导致编解码操作中会损失块的位置数据，还会产生数据读取和传输的高通信成本。Ye 等^[68] 提出了 Hybrid-RC 利用 Butterfly 码来对 MSR 进行优化改进，理论上它是可以在低存储开销和低修复带宽之间取得最优均衡的纠删码。Hybrid-RC 使用 Butterfly 作为分组校验编码的编码策略，使用伽罗瓦运算进行全局校验码的计算从而保持存储系统的可靠性。与 LRC 相比，在相同的存储开销下，Hybrid-RC 在处理单块故障恢复时有着更多的数据块参与。每个块的 I/O 消耗相对减少且数据传输是高度并行的，从而达到了良好的平衡。Hybrid-RC 由三个标准化参数组成， k, l, g ，记为 $A(k, l, g)$ 。一个条带中有 k 个数据块和 $l + g$ 个校验块，其中 g 个全局校验块通过对所有数据块进行伽罗瓦运算求出。Hybrid-RC 将 k 块数据分成 $\frac{l}{2}$ 个组，其中 l 必须为偶数。当 k 不能被 $\frac{l}{2}$ 整除时且余数为 r 时，那么第 0 到第 $r - 1$ 组应该包含 $\left\lceil \frac{2k}{l} \right\rceil$ 个块并且每个块被分成了 $2(\lceil \frac{2k}{l} \rceil - 1)$ 个片段。如果不同的组的切片数不同，那么从第 $r - 1$ 个到第 $\frac{l}{2} - 1$ 个组应该加倍以保证每个块的存储消耗保持一样。例如，考虑 $A(7, 4, 1)$ 的 Hybrid-RC 码，节点中的每个块大小为 1GB。第一个组包含 4 个数据块和 2 个校验块，所以每个块有 8 个切片且每个切片大小为 0.125GB。但是，第二个组只有 3 个数据块，因此每个块有 4 个切片。为了两个组能保持同样的块大小，第二组的每个块大小需要为 0.25GB。总的来说，不同组的奇偶块构建和块修复是相互独立的。对于全局编码或修复，最小的操作元素是相同的。因此，不同数量或大小的切片对全局奇偶校验计算是没有影响的。

全局

D_0	D_1	D_2	D_3	D_4	D_5	D_6	$P_{g,0}$
D_0	D_1	D_2	D_3	D_4	D_5	D_6	$D_0 + 2D_1 + 4D_2 + 8D_3 + 16D_4 + 32D_5 + 64D_6$

第2个组

D_4	D_5	D_6	$P_{h,1}$	$P_{b,1}$
$D_{4,0}$	$D_{5,0}$	$D_{6,0}$	$D_{4,0} + D_{5,0} + D_{6,0}$	$D_{4,3} + D_{5,1} + D_{6,0}$
$D_{4,1}$	$D_{5,1}$	$D_{6,1}$	$D_{4,1} + D_{5,1} + D_{6,1}$	$D_{4,2} + D_{5,0} + D_{6,0} + D_{6,1}$
$D_{4,2}$	$D_{5,2}$	$D_{6,2}$	$D_{4,2} + D_{5,2} + D_{6,2}$	$D_{4,1} + D_{5,1} + D_{6,1} + D_{5,3} + D_{6,3} + D_{6,2}$
$D_{4,3}$	$D_{5,3}$	$D_{6,3}$	$D_{4,3} + D_{5,3} + D_{6,3}$	$D_{4,0} + D_{5,0} + D_{6,0} + D_{5,2} + D_{6,3}$

图 2-1 (7,4,1)Hybrid-RC

2.1 基于感知修复的研究现状

2.2 基于改进纠删码结构存储数据研究现状

2.3 基于调度优化的数据修复研究现状

第三章 面向纠删码构建的存储系统中预测修复技术研 究

3.1 预测修复算法

3.2 修复调度算法

3.3 实验结果分析

第四章 面向纠删码构建的存储系统中修复调度研究

第五章 基于预测修复的纠删码存储系统原型设计与实现

第六章 总结与展望

参 考 文 献

- [1] Rydning D R J G J, Reinsel J, Gantz J. The digitization of the world from edge to core [J]. Framingham: International Data Corporation, 2018: 16.
- [2] Wang S, Zhang Y, Zhang Y. A blockchain-based framework for data sharing with fine-grained access control in decentralized storage systems [J]. Ieee Access, 2018, 6: 38437-38450.
- [3] Sathiamoorthy M, Asteris M, Papailiopoulos D, Dimakis A G, Vadali R, Chen S, Borthakur D. Xoring elephants: Novel erasure codes for big data [J]. arXiv preprint arXiv:1301.3791, 2013.
- [4] Ghemawat S, Gobioff H, Leung S T. The google file system [C]//Proceedings of the nineteenth ACM symposium on Operating systems principles. 2003: 29-43.
- [5] Borthakur D, et al. Hdfs architecture guide [J]. Hadoop apache project, 2008, 53(1-13): 2.
- [6] Weatherspoon H, Kubiatowicz J D. Erasure coding vs. replication: A quantitative comparison [C]//International Workshop on Peer-to-Peer Systems. Springer, 2002: 328-337.
- [7] Ford D, Labelle F, Popovici F I, Stokely M, Truong V A, Barroso L, Grimes C, Quinlan S. Availability in globally distributed storage systems [C]//9th USENIX Symposium on Operating Systems Design and Implementation (OSDI 10). 2010.
- [8] Huang C, Simitci H, Xu Y, Oqus A, Calder B, Gopalan P, Li J, Yekhanin S. Erasure coding in windows azure storage [C]//2012 USENIX Annual Technical Conference (USENIX ATC 12). 2012: 15-26.
- [9] Muralidhar S, Lloyd W, Roy S, Hill C, Lin E, Liu W, Pan S, Shankar S, Sivakumar V, Tang L, et al. f4: Facebook's warm {BLOB} storage system [C]//11th USENIX Symposium on Operating Systems Design and Implementation (OSDI 14). 2014: 383-398.
- [10] Ovsianikov M, Rus S, Reeves D, Sutter P, Rao S, Kelly J. The quantcast file system [J]. Proceedings of the VLDB Endowment, 2013, 6(11): 1092-1101.
- [11] Reed I S, Solomon G. Polynomial codes over certain finite fields [J]. Journal of the society for industrial and applied mathematics, 1960, 8(2): 300-304.

- [12] Wu Y, Dimakis A G. Reducing repair traffic for erasure coding-based storage via interference alignment [C]//2009 IEEE International Symposium on Information Theory. IEEE, 2009: 2276-2280.
- [13] Kamath G M, Prakash N, Lalitha V, Kumar P V. Codes with local regeneration and erasure correction [J]. IEEE Transactions on information theory, 2014, 60(8): 4637-4660.
- [14] Li Y, He B, Luo Q, Yi K. Tree indexing on flash disks [C]//2009 IEEE 25th International Conference on Data Engineering. IEEE, 2009: 1303-1306.
- [15] Hua Y, Jiang H, Zhu Y, Feng D, Tian L. Smartstore: A new metadata organization paradigm with semantic-awareness for next-generation file systems [C]//Proceedings of the conference on high performance computing networking, storage and analysis. IEEE, 2009: 1-12.
- [16] Weil S A, Pollack K T, Brandt S A, Miller E L. Dynamic metadata management for petabyte-scale file systems [C]//SC'04: Proceedings of the 2004 ACM/IEEE conference on Supercomputing. IEEE, 2004: 4-4.
- [17] Al-Fares M, Loukissas A, Vahdat A. A scalable, commodity data center network architecture [J]. ACM SIGCOMM computer communication review, 2008, 38(4): 63-74.
- [18] Greenberg A, Hamilton J R, Jain N, Kandula S, Kim C, Lahiri P, Maltz D A, Patel P, Sengupta S. Vi2: a scalable and flexible data center network [J]. Communications of the ACM, 2011, 54(3): 95-104.
- [19] Guo C, Wu H, Tan K, Shi L, Zhang Y, Lu S. Dcell: a scalable and fault-tolerant network structure for data centers [C]//Proceedings of the ACM SIGCOMM 2008 conference on Data communication. 2008: 75-86.
- [20] Guo C, Lu G, Li D, Wu H, Zhang X, Shi Y, Tian C, Zhang Y, Lu S. Bcube: a high performance, server-centric network architecture for modular data centers [C]//Proceedings of the ACM SIGCOMM 2009 conference on Data communication. 2009: 63-74.
- [21] Shvachko K, Kuang H, Radia S, Chansler R. The hadoop distributed file system [C]//2010 IEEE 26th symposium on mass storage systems and technologies (MSST). Ieee, 2010: 1-10.
- [22] 王意洁, 许方亮, 裴晓强. 分布式存储中的纠删码容错技术研究 [J]. 计算机学报, 2017, 40(1): 236-255.

- [23] Lakshman A, Malik P. Cassandra: a decentralized structured storage system [J]. ACM SIGOPS Operating Systems Review, 2010, 44(2): 35-40.
- [24] Gill N K, Singh S. A dynamic, cost-aware, optimized data replication strategy for heterogeneous cloud data centers [J]. Future Generation Computer Systems, 2016, 65: 10-32.
- [25] Gai-Mei G, Shang-Wang B. Design and simulation of dynamic replication strategy for the data grid [C]//2012 International Conference on Industrial Control and Electronics Engineering. IEEE, 2012: 901-903.
- [26] Patterson D A, Gibson G, Katz R H. A case for redundant arrays of inexpensive disks (raid) [C]//Proceedings of the 1988 ACM SIGMOD international conference on Management of data. 1988: 109-116.
- [27] Chen P M, Lee E K, Gibson G A, Katz R H, Patterson D A. Raid: High-performance, reliable secondary storage [J]. ACM Computing Surveys (CSUR), 1994, 26(2): 145-185.
- [28] Lin W, Chiu D M, Lee Y. Erasure code replication revisited [C]//Proceedings. Fourth International Conference on Peer-to-Peer Computing, 2004. Proceedings. IEEE, 2004: 90-97.
- [29] Huang S, Hou H, Yu X. A lower bound on disk reads for single information disk failure recovery and one recovery scheme for evenodd (p, 3) [C]//2019 Ninth International Workshop on Signal Design and its Applications in Communications (IWSDA). IEEE, 2019: 1-5.
- [30] Xu L, Bruck J. X-code: Mds array codes with optimal encoding [J]. IEEE Transactions on Information Theory, 1999, 45(1): 272-276.
- [31] Roth R M, Lempel A. On mds codes via cauchy matrices [J]. IEEE transactions on information theory, 1989, 35(6): 1314-1319.
- [32] Xia H, Chien A A. Robustore: a distributed storage architecture with robust and high performance [C]//SC'07: Proceedings of the 2007 ACM/IEEE Conference on Supercomputing. IEEE, 2007: 1-11.
- [33] Kubiatowicz J, Bindel D, Chen Y, Czerwinski S, Eaton P, Geels D, Gummadi R, Rhea S, Weatherspoon H, Weimer W, et al. Oceanstore: An architecture for global-scale persistent storage [J]. ACM SIGOPS Operating Systems Review, 2000, 34(5):

- 190-201.
- [34] Blaum M, Bruck J, Vardy A. Mds array codes with independent parity symbols [J]. IEEE Transactions on Information Theory, 1996, 42(2): 529-542.
- [35] Plank J S. The raid-6 liber8tion code [J]. The International Journal of High Performance Computing Applications, 2009, 23(3): 242-251.
- [36] Hafner J L, Deenadhayalan V, Rao K, Tomlin J A. Matrix methods for lost data reconstruction in erasure codes. [C]//FAST: volume 5. 2005: 15-30.
- [37] Li P, Li J, Stones R J, Wang G, Li Z, Liu X. Procode: A proactive erasure coding scheme for cloud storage systems [C]//2016 IEEE 35th Symposium on Reliable Distributed Systems (SRDS). IEEE, 2016: 219-228.
- [38] Blaum M, Brady J, Bruck J, Menon J. Evenodd: An efficient scheme for tolerating double disk failures in raid architectures [J]. IEEE Transactions on computers, 1995, 44(2): 192-202.
- [39] Corbett P, English B, Goel A, Grcanac T, Kleiman S, Leong J, Sankar S. Row-diagonal parity for double disk failure correction [C]//Proceedings of the 3rd USENIX Conference on File and Storage Technologies. San Francisco, CA, 2004: 1-14.
- [40] Feng J, Chen Y, Summerville D. Eeo: An efficient mds-like raid-6 code for parallel implementation [C]//2010 IEEE Sarnoff Symposium. IEEE, 2010: 1-5.
- [41] Huang C, Xu L. Star: An efficient coding scheme for correcting triple storage node failures [J]. IEEE Transactions on Computers, 2008, 57(7): 889-901.
- [42] Feng J B, Wu H C, Tsai C S, Chu Y P. A new multi-secret images sharing scheme using largrange's interpolation [J]. Journal of Systems and Software, 2005, 76(3): 327-339.
- [43] Ahlswede R, Cai N, Li S Y, Yeung R W. Network information flow [J]. IEEE Transactions on information theory, 2000, 46(4): 1204-1216.
- [44] Dimakis A G, Godfrey P B, Wu Y, Wainwright M J, Ramchandran K. Network coding for distributed storage systems [J]. IEEE transactions on information theory, 2010, 56 (9): 4539-4551.
- [45] Wu Y, Dimakis A G, Ramchandran K. Deterministic regenerating codes for distributed storage [C]//Allerton conference on control, computing, and communication. IEEE Press Washington DC, 2007: 1-5.
- [46] Calder B, Wang J, Oguis A, Nilakantan N, Skjolsvold A, McKelvie S, Xu Y, Srivastav S,

- Wu J, Simitci H, et al. Windows azure storage: a highly available cloud storage service with strong consistency [C]//Proceedings of the Twenty-Third ACM Symposium on Operating Systems Principles. 2011: 143-157.
- [47] Huang C, Chen M, Li J. Pyramid codes: Flexible schemes to trade space for access efficiency in reliable data storage systems [J]. ACM Transactions on Storage (TOS), 2013, 9(1): 1-28.
- [48] 周松, 王意洁. EXPyramid: 一种灵活的基于阵列结构的高容错低修复成本编码方案 [J]. 计算机研究与发展, 2011, 1.
- [49] Woitaszek M, Tufo H M. Tornado codes for maid archival storage [C]//24th IEEE Conference on Mass Storage Systems and Technologies (MSST 2007). IEEE, 2007: 221-226.
- [50] Gallager R. Low-density parity-check codes [J]. IRE Transactions on information theory, 1962, 8(1): 21-28.
- [51] Hafner J L. Weaver codes: Highly fault tolerant erasure codes for storage systems. [C]//Fast: volume 5. 2005: 16-16.
- [52] Hafner J L. Hover erasure codes for disk arrays [C]//International Conference on Dependable Systems and Networks (DSN'06). IEEE, 2006: 217-226.
- [53] Shah N B, Rashmi K, Kumar P V. A flexible class of regenerating codes for distributed storage [C]//2010 IEEE International Symposium on Information Theory. IEEE, 2010: 1943-1947.
- [54] Li J, Yang S, Wang X, Li B. Tree-structured data regeneration in distributed storage systems with regenerating codes [C]//2010 Proceedings IEEE INFOCOM. IEEE, 2010: 1-9.
- [55] 许方亮, 王意洁, 裴晓强. NTar: 基于网络拓扑的纠删码树型修复方法 [J]. 计算机研究与发展, 2013, 2.
- [56] Weidong S, Yijie W, Xiaoqiang P. Tree-structured parallel regeneration for multiple data losses in distributed storage systems based on erasure codes [J]. China Communications, 2013, 10(4): 113-125.
- [57] Xiang L, Xu Y, Lui J C, Chang Q. Optimal recovery of single disk failure in rdp code storage systems [J]. ACM SIGMETRICS Performance Evaluation Review, 2010, 38 (1): 119-130.

- [58] Khan O, Burns R C, Plank J S, Pierce W, Huang C. Rethinking erasure codes for cloud file systems: minimizing i/o for recovery and degraded reads. [C]//FAST: volume 20. 2012: 2208461-2208481.
- [59] Zhu Y, Lin J, Lee P P, Xu Y. Boosting degraded reads in heterogeneous erasure-coded storage systems [J]. IEEE Transactions on Computers, 2014, 64(8): 2145-2157.
- [60] Niu F, Xu Y, Zhu Y, Zhang Y. Phr: A pipelined heterogeneous recovery for raid6-coded storage systems [C]//2013 International Conference on Parallel and Distributed Computing, Applications and Technologies. IEEE, 2013: 325-331.
- [61] Zhu Y, Lee P P, Xiang L, Xu Y, Gao L. A cost-based heterogeneous recovery scheme for distributed storage systems with raid-6 codes [C]//IEEE/IFIP International Conference on Dependable Systems and Networks (DSN 2012). IEEE, 2012: 1-12.
- [62] Popa L, Yalagandula P, Banerjee S, Mogul J C, Turner Y, Santos J R. Elasticswitch: Practical work-conserving bandwidth guarantees for cloud computing [C]//Proceedings of the ACM SIGCOMM 2013 conference on SIGCOMM. 2013: 351-362.
- [63] Li S, Lan T, Ra M R, Panta R. Joint scheduling and source selection for background traffic in erasure-coded storage [J]. IEEE Transactions on Parallel and Distributed Systems, 2018, 29(12): 2826-2837.
- [64] Rashmi K V, Shah N B, Gu D, Kuang H, Borthakur D, Ramchandran K. A "hitch-hiker's" guide to fast and efficient data reconstruction in erasure-coded data centers [C]//Proceedings of the 2014 ACM conference on SIGCOMM. 2014: 331-342.
- [65] Xia M, Saxena M, Blaum M, Pease D A. A tale of two erasure codes in {HDFS} [C]// 13th USENIX conference on file and storage technologies (FAST 15). 2015: 213-226.
- [66] Dimakis A G, Godfrey P B, Wainwright M J, Ramchandran K. The benefits of network coding for peer-to-peer storage systems [C]//Third Workshop on Network Coding, Theory, and Applications. 2007.
- [67] Pamies-Juarez L, Blagojevic F, Mateescu R, Gyuot C, Gad E E, Bandic Z. Opening the chrysalis: On the real repair performance of {MSR} codes [C]//14th USENIX conference on file and storage technologies (FAST 16). 2016: 81-94.
- [68] Ye L, Feng D, Hu Y, Liu Q. Hybrid-rc: Flexible erasure codes with optimized recovery performance and low storage overhead [C]//2017 IEEE 36th Symposium on Reliable Distributed Systems (SRDS). IEEE, 2017: 124-133.

攻读学位期间的成果

• 论文

- (1) 叶冬冬. 基于纠删码的存储系统中高可靠预测修复客户端软件, 计算机软件著作权, 未发表, 登记号: 2022SR0208709.
- (2) 叶冬冬. 基于纠删码的存储系统中高可靠预测修复服务端软件, 计算机软件著作权, 未发表, 登记号: 2022SR0208720.

• 比赛

- (1) 2020 中国研究生数学建模竞赛, 二等奖.

• 实习

- (1) 2021/7--2021/8. 苏州-中国农业银行-分行计算机中心.

攻读学位期间的主要科研工作

- (1) 国防科技创新特区支持, 江苏省高校优势学科建设资助项目. 区块链存储系统. 2018-2021.

致谢

养天地正气，法古今完人。从本科到硕士，转眼间在美丽的苏州大学校园内度过了七年的求学时光。在这段不算短的人生旅途中，无论是学识上还是生活阅历上我都成长良多。

首先，我要感谢我的导师李正华老师。李老师永远以饱满的热情和专注的态度面对工作和生活，永远是我以后求学和工作的一个榜样。

感谢尊敬的张民老师，张老师以高标准要求每一个学生，营造了组内浓厚专一的科研氛围。此外，张老师敏锐的思维、渊博的知识、平易近人的风格、深深的影响了我，平时的相处让我获益良多。感谢陈文亮老师，陈老师开朗热情，在学业上给予了我很多指导。同样感谢周国栋、朱巧明、李寿山、洪宇、段湘煜和李军辉等苏州大学自然语言处理实验室的所有老师，各位老师严谨的治学态度和进取的专业精神是我的榜样。

感谢周厚全师弟，厚全师弟涉猎广博，热爱阅读，富有好奇心，在平时的讨论中总是能给我很多启发。在课题研究上我们有很多合作，也取得了很多成果，希望以后继续合作，互相促进。

感谢同组的夏庆荣师兄、龚晨师姐、李英师姐和张月师姐，各位师兄师姐总是十分热心的解决我生活和研究上遇到的困难。感谢章波、黄德朋、江心舟师兄，彭雪师姐，在我还是萌新的时候对我的帮助，以及平时对我的关照。感谢同届的蒋炜、陆凯华、吴锟、刘亚慧同学，大家在一起互相帮助，互相进步。感谢沈嘉钰、李嘉诚、侯洋、李帅克、周仕林、刘泽洋、李扬师弟，还有周明月、杨浩萍师妹，十分珍惜与大家相处的美好时光。

此外，还要感谢实习期间相处的王涛师兄、蒋勇师兄，以及王新宇、胡泽川、蔡炯和马欣尹同学。特别是感谢蒋勇师兄在我实习期间对我的关照，以及在课题研究上的悉心帮助和指导。

感谢我的父母还有家人们，你们总是我心灵上的港湾和寄托，无论何时都能给我最无私的帮助。

最后，我还要感谢各位评审老师，感谢各位老师们在百忙之中抽取时间对本文进行评审，并提出宝贵的修改意见。

学位论文答辩委员会决议

- 包括：1、对论文的评价，包括选题的理论价值和实践意义，论文理论、方法上的开拓与创新，论据的可靠充分与结论的正确性；论文所反映的作者学术视野（对本学科及相关领域研究动态的把握）、基础理论、专业知识、写作能力等；
2、对答辩的评价；
3、是否同意通过论文答辩，是否建议授予学位或是否建议在规定时间内修改论文后重新答辩一次的结论。

论文在依存句法分析和成分句法分析这两种句法分析任务上，探讨了基于树形条件随机场的高阶方法对句法分析器性能和效率的影响。选题具有很好的理论价值和实践意义，以及一定的创新性。目前主流的句法分析方法大多基于神经网络方法，并采用了一个简化的学习目标，相对应地，传统方法中大多采用了结构化学习以及高阶建模。论文针对这一对比，提出了将当前的句法分析器与传统方法做一个联结。论文提出在神经网络模型中采用树形条件随机场来最大化树概率，并进一步提出采用高阶建模。为了改善带来的效率问题，论文分别尝试了批次化计算和变分推断近似方法来加速。结果表明结构化建模和高阶方法对于目前的句法分析器仍然是有益的。

作者比较全面地论述了相关研究领域国内外研究情况，所采用的研究方法和技术手段体现了作者良好的学术研究基础和能力。论文成果在研究方法等方面有所创新，其中的新方法、新思路具备了很好的应用价值。论文写作层次清晰，逻辑结构合理，文字流畅，符合学术规范。

论文质量优秀。答辩过程中陈述清楚，回答问题准确。

答辩委员会经讨论，认为该论文已达到硕士学位论文水平，一致同意其通过论文答辩，建议授予硕士学位。

答辩委员会主席：_____ 孔芳 _____ 秘书：_____ 张雅静 _____

委员：_____ 陈文亮 _____、_____ 李培峰 _____、_____ 钱龙华 _____、_____ 朱晓旭 _____

_____、_____、_____、_____、_____

2021 年 5 月 22 日

注：本表内容（包括答辩名单）可手签或打印